Rapport Prédiction spatiale — SSU Bokengi

Généré le 26/06/2026 à 22:36 — EDA, nettoyage, validation croisée, sélection modèle, gold_eval.

Indicateur	Valeur
Signalements (nettoyés)	311
Train / Val / Test / Gold	191 / 40 / 33 / 47
Modèle retenu	GradientBoosting
F1 macro (test hold-out)	0.14814814814814814
F1 macro (gold_eval)	0.38468428123600534
Accuracy (gold)	0.40425531914893614

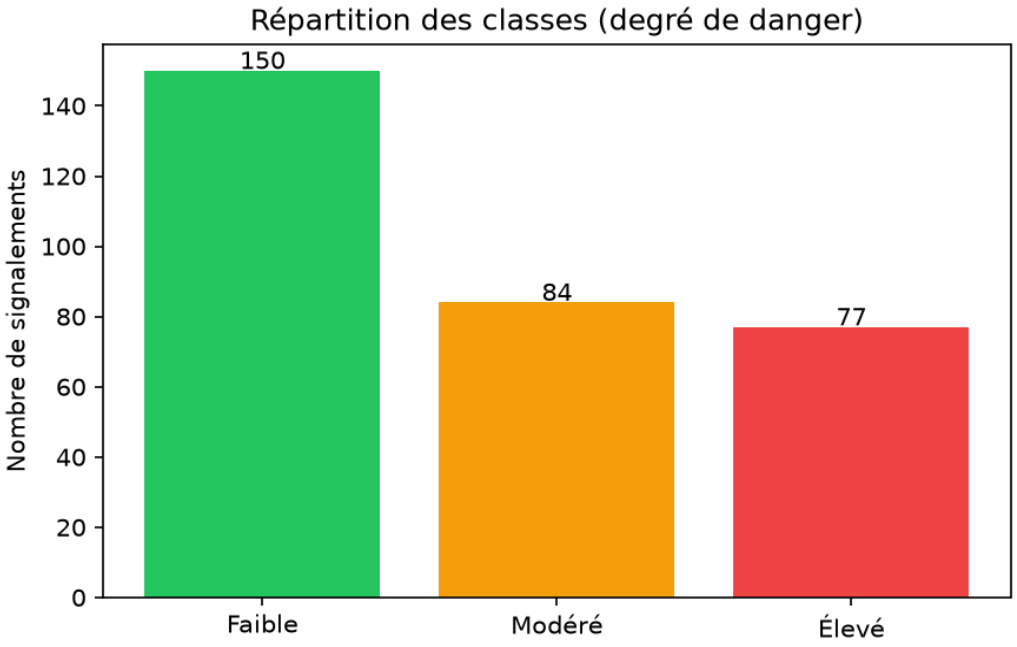
1. Objectif

Prédire le **degré de danger** (faible, modéré, élevé) à partir de la géolocalisation et du contexte spatio-temporel des signalements validés. Le modèle alimente la carte de chaleur 48×48 et le microservice prediction-service.

2. Sources et nettoyage

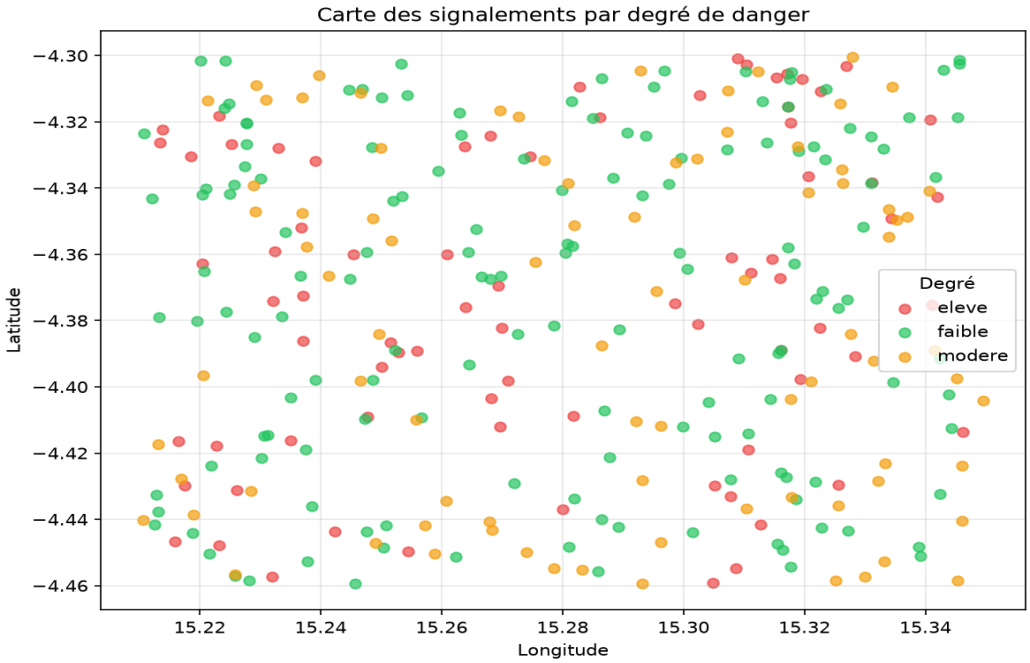
Lignes lues : 312. Conservées : 311. Rejet coords invalides : 0. Hors bbox Kinshasa : 0. Degré invalide : 1. Doublons : 0.

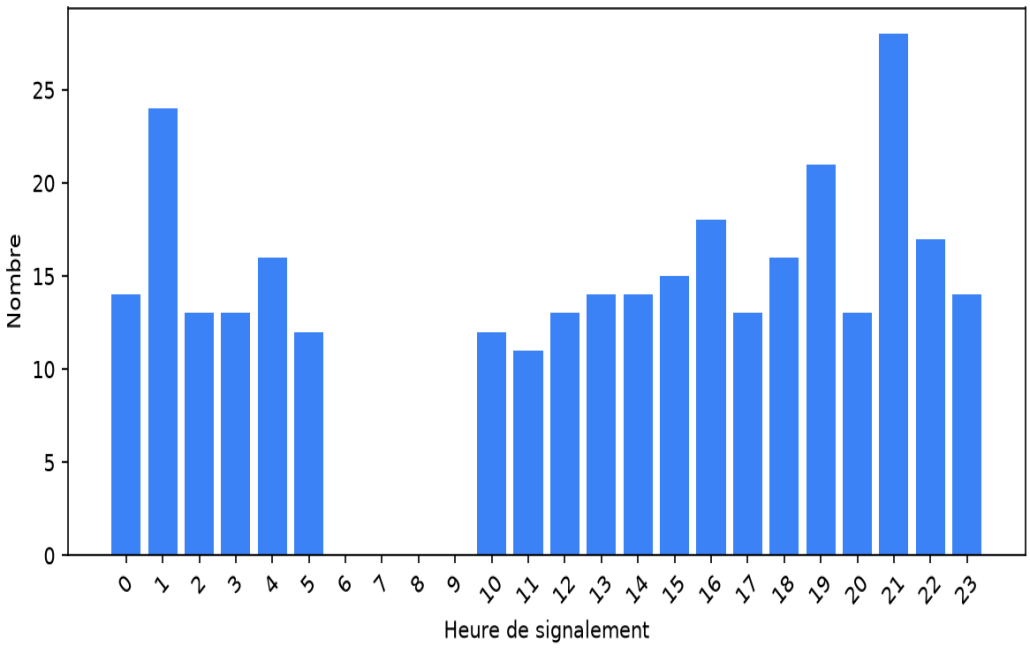
Classe	Effectif
faible	150
modere	84
eleve	77

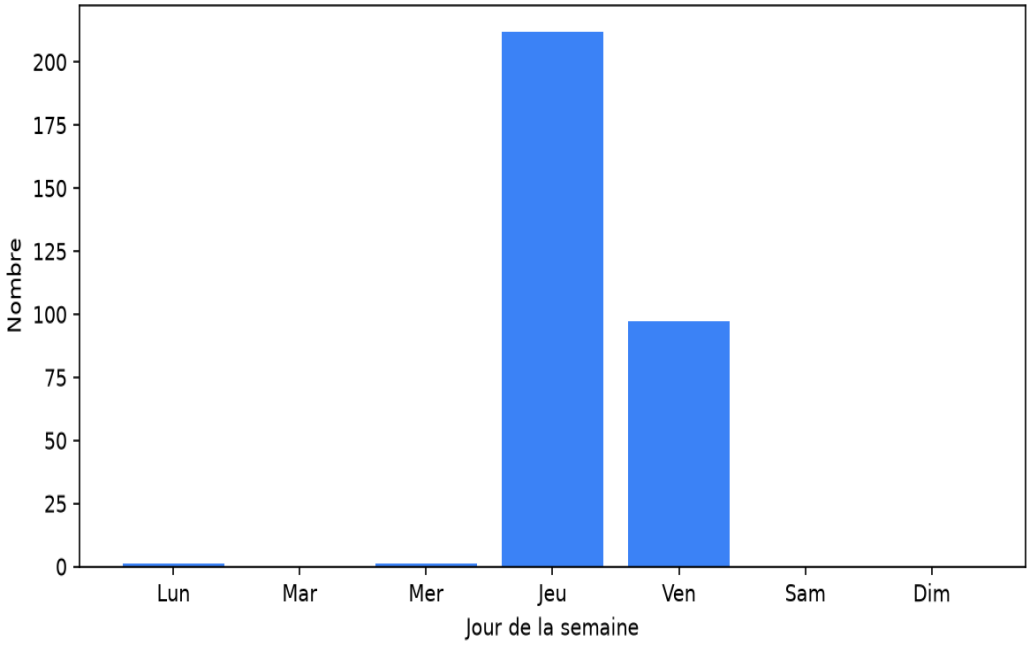


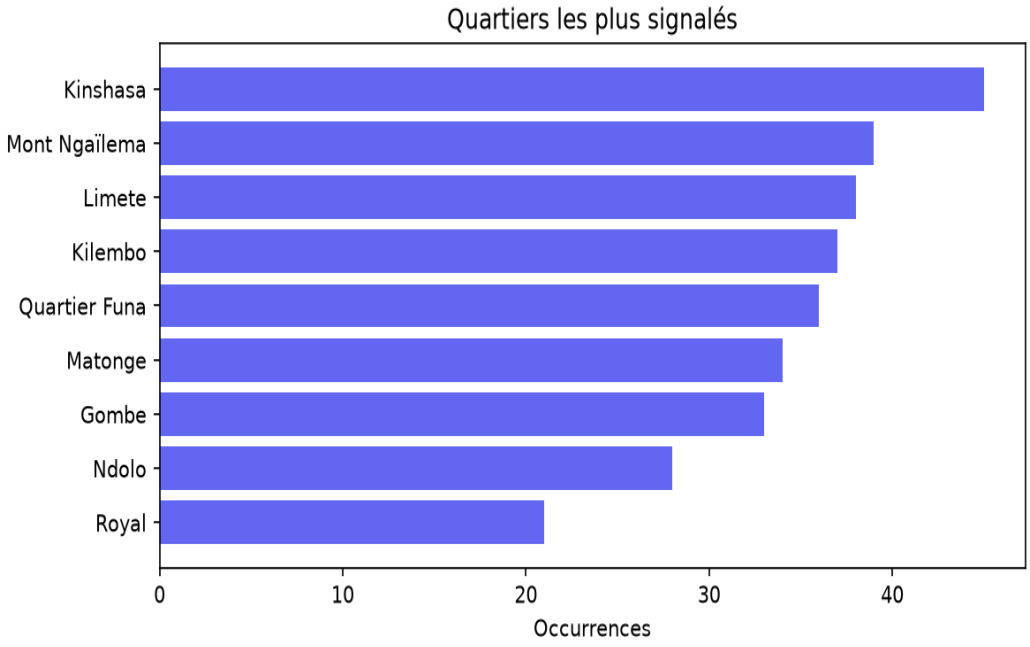
3. Analyse exploratoire (EDA)

Centroïde approx. : lat -4.375510032154341, lon 15.280390868167201. Période : 2025-01-02 10:14:00 → 2025-02-05 13:38:11.


Carte des signalements par degré de danger
Latitude
Longitude
−4.30
−4.32
−4.34
−4.36
−4.38
−4.40
−4.42
−4.44
−4.46
15.22
15.24
15.26
15.28
15.30
15.32
15.34
Degré
eleve
faible
modere


Nombre
Heure de signalement
0
5
10
15
20
25
0 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23





4. Features et ingénierie

Variables d'entrée (6) : latitude, longitude, hour, day_of_week, density_500m, mean_neighbor_degree. La densité locale (rayon 500 m, BallTree haversine) et le degré moyen des voisins sont calculés en **leave-one-out** à l'entraînement pour éviter la fuite de label.

• Export signalements validés (statut V) depuis PostgreSQL → data_reports.csv

• Nettoyage : coords valides, bbox Kinshasa, normalisation degré (faible/modéré/élevé)

• Déduplication lat/lon/timestamp (arrondi minute)

• Imputation created_at manquant → 2025-01-01 12:00

• Split stratifié seed=42 : gold 15 %, val 15 %, test 15 %, reste train

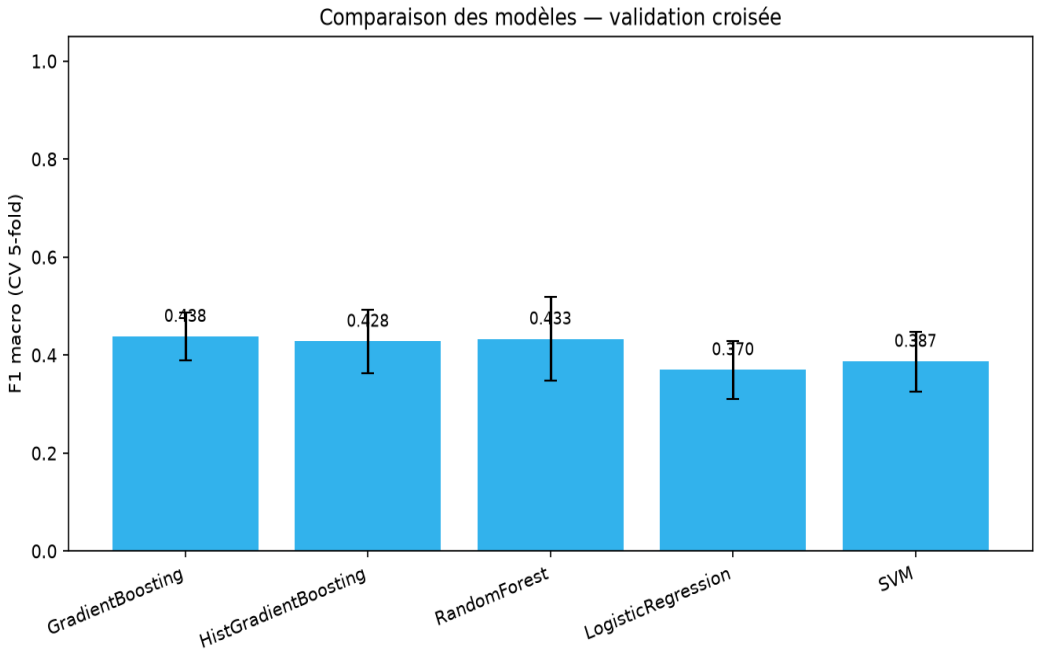
• Features : lat, lon, heure, jour semaine, densité 500 m, degré moyen voisins (sans fuite LOO)

• StandardScaler + validation croisée 5-fold + sélection modèle (F1 macro)

5. Validation croisée et sélection de modèles

Meilleur F1 macro en validation croisée (5-fold) sur le jeu train : GradientBoosting (F1=0.438 ± 0.049)

Modèle	F1 macro (moy.)	Écart-type	Accuracy (moy.)
GradientBoosting	0.4379	±0.0491	0.4818
HistGradientBoosting	0.4277	±0.0653	0.4873
RandomForest	0.4327	±0.0853	0.4980
LogisticRegression	0.3697	±0.0595	0.3671
SVM	0.3868	±0.0607	0.3930



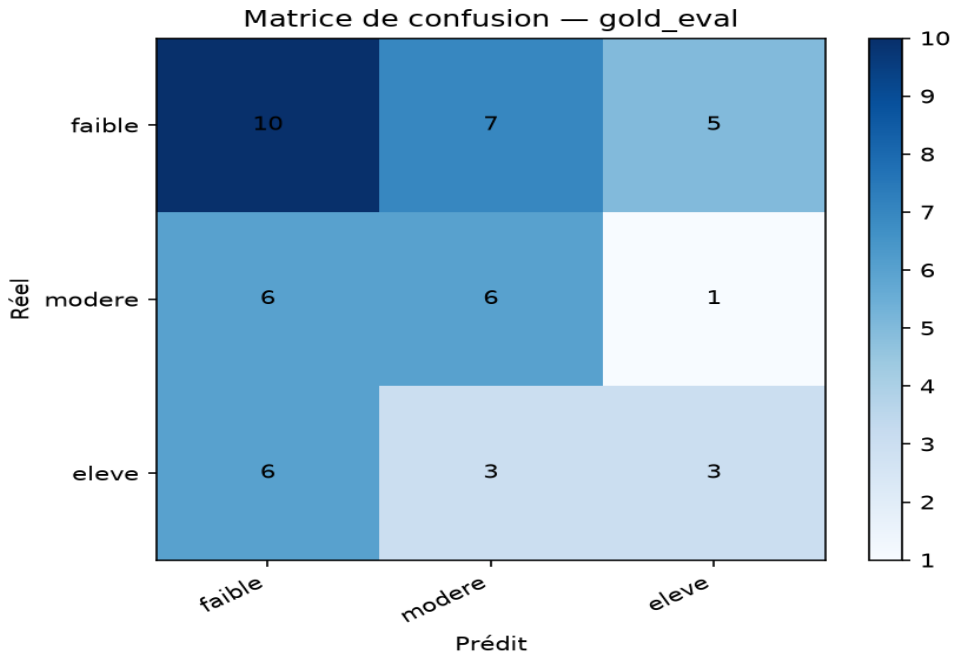
6. Résultats hold-out (test)

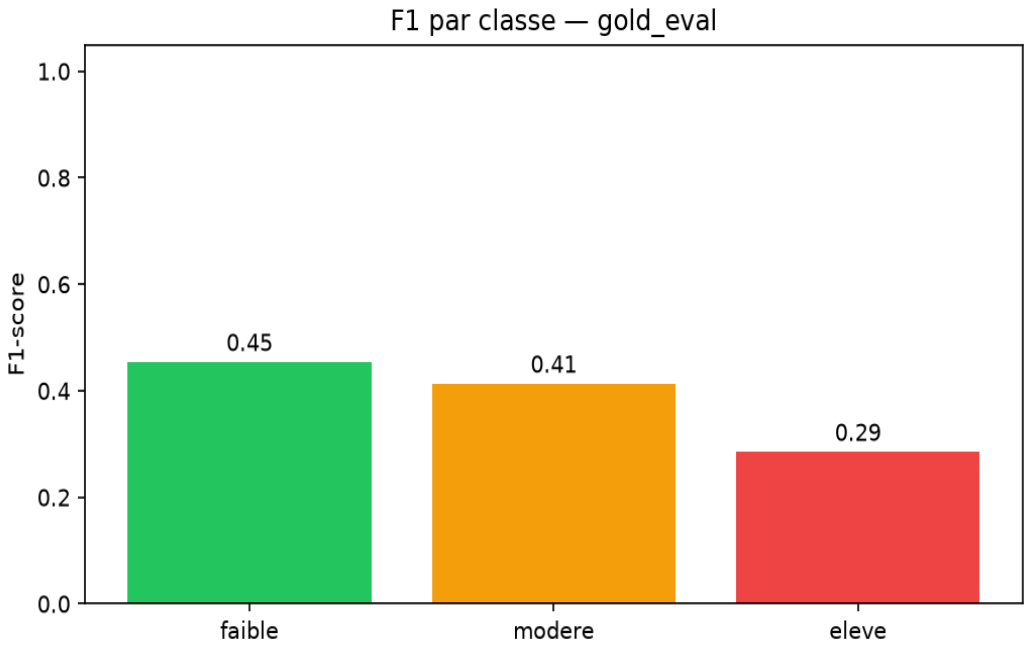
Accuracy : 0.24242424242424243. F1 macro : 0.14814814814814814. F1 weighted : 0.21548821548821548.

7. Résultats gold_eval

Échantillons gold : 47. Accuracy : 0.40425531914893614. F1 macro : 0.38468428123600534. Précision macro : 0.3876262626262626. Rappel macro : 0.38869463869463866.

Classe	Precision	Recall	F1
faible	0.455	0.455	0.455
modere	0.375	0.462	0.414
eleve	0.333	0.250	0.286





8. Recommandations

• Augmenter le volume de signalements validés (statut V) pour stabiliser la CV.
• Surveiller le déséquilibre entre classes faible / modéré / élevé.
• Réentraîner après export CSV (Celery :05) ou manuellement.
• Commandes : `bash scripts/run_prediction_retrain.sh`, `python scripts/generate_prediction_report.py`